Ahmed FAKHFAKH

Tél : +33 6 02 48 74 81 | Email : fakhfakhahmed45@gmail.com | LinkedIn : https://www.linkedin.com/in/afakhfakh/
Portfolio : https://ahmedfakhfakh.netlify.app | GitHub : https://github.com/FakhAhmed

AI Engineer | Data Engineer | MLOps | Edge AI

Recherche d'un CDI – Disponible immédiatement

Ingénieur Data et IA diplômé de Polytech Nantes (2026), 3 ans d'alternance en R&D IA embarquée chez OPmobility. J'industrialise des systèmes d'IA, du pipeline de données GCP à l'inférence optimisée : LLM et RAG multi-agents, MLOps, Deep Learning sur NVIDIA Jetson (TensorRT). Certifié Google Cloud Professional Data Engineer.

CERTIFICATIONS

Google Cloud Certified – Professional Data Engineer | Associate Cloud Engineer | Cloud Digital Leader

COMPÉTENCES

— **Langages & Cloud :** Python, SQL, Bash, R, GCP (BigQuery, Vertex AI, Cloud Run, Cloud Build, Cloud Storage)
— **IA & LLM :** PyTorch, Scikit-Learn, XGBoost, LangGraph, LlamaIndex, Qdrant, Hugging Face (LoRA)
— **Edge AI & Optimisation :** TensorRT (FP16/INT8), ONNX, NVIDIA Jetson, profilage GPU (Perfetto), modèles Sparse
— **Data Engineering & MLOps :** Apache Airflow, dbt, Spark, Kafka, Flink, Iceberg, MLflow, DVC, LangSmith
— **DevOps & Outils :** Terraform, Docker, CI/CD (Cloud Build, GitHub Actions, GitLab CI), FastAPI, Git, Linux

EXPÉRIENCE PROFESSIONNELLE

Apprenti Ingénieur IA Embarqué | OPmobility (OP'nSoft, R&D) | Levallois-Perret **Oct. 2023 – Sep. 2026**

— **Déploiement Edge AI & Profiling :** Portage d'un modèle de détection radar 4D sur NVIDIA Jetson AGX Orin (banc Hardware-in-the-Loop). TensorRT FP16 : latence GPU de 865 à 188 ms (×4,6), RAM de 10,2 à 3,5 Go, précision préservée (Pd 0,58 vs 0,59).
— **Optimisation & Diagnostic :** Étude d'ablation (Sparse, MobileNet-V2, cache FIFO en multiprocessing, distillation, INT8) ; diagnostic du *Mixed Precision Fallback* rendant l'INT8 plus lent que le FP16.
— **R&D Attention (co-auteur, IEEE RadarConf 2027) :** Co-conception, implémentation et déploiement TensorRT d'un tokenizer radar et d'un transformer à attention asymétrique, avec protocole de benchmark sur Jetson : détection équivalente au CNN de référence, 3,6× moins de calculs, 21 FPS (vs 7,2), 4× moins d'énergie.
— **Stack technique :** Python, PyTorch, TensorRT, ONNX, CUDA, NVIDIA Jetson, Multiprocessing.

PUBLICATION

Tailored Attention Mechanism for Radar Point-Cloud Generation on Embedded GPUs – A. Hernandez, A. Pegatoquet, J.-Y. Dauvignac, R. Christy-Krishanth, **A. Fakhfakh**. *Soumis à IEEE RadarConf 2027.*

PROJETS TECHNIQUES

Agentic AI Financier Multimodal – Architecture Multi-Agents & LLMOps Lien GitHub | **2025 – 2026**

— Superviseur LangGraph routant chaque requête vers 4 agents : SQL BigQuery auto-correctif, RAG documentaire (ChromaDB), cours de bourse en temps réel, conversationnel.
— Garde-fou anti prompt-injection en entrée du graphe ; traçage LangSmith de la latence et du coût par agent (≈ 0,007 $ la requête).
— Déploiement serverless Docker sur Cloud Run (interface Streamlit en streaming), infrastructure Terraform.
— **Stack & Outils :** Vertex AI Gemini, LangGraph, LangChain, BigQuery, ChromaDB, LangSmith, Terraform.

Modern Data Stack & RAG avec détection d'hallucinations Lien GitHub | **2025 – 2026**

— Pipeline ELT : nettoyage de tickets de support IT avec dbt sur BigQuery (tests d'intégrité), embeddings Vertex AI et indexation Qdrant.
— RAG LlamaIndex sur Cloud Run, avec évaluation automatique de chaque réponse (fidélité, pertinence) et affichage des sources.
— Orchestration serverless quotidienne (Cloud Scheduler + Cloud Run Jobs), plus économique qu'Airflow.
— **Stack & Outils :** dbt, BigQuery, Vertex AI, LlamaIndex, Qdrant, Cloud Run, Docker.

Autres projets : Streaming anti-fraude (Kafka, PyFlink, Iceberg) | Fine-tuning QLoRA Llama-3 8B (MLflow, DVC) | API MLOps XGBoost (FastAPI, Cloud Build, Vertex AI).

FORMATION

Diplôme d'Ingénieur en Data & IA (par apprentissage) | Polytech Nantes, France **Oct. 2023 - Sep. 2026**
Cours : Data Science, Machine Learning, Deep Learning, Computer Vision, MLOps.

DUT Informatique | IUT de Bayonne et du Pays Basque, France **Sep. 2021 - Juin 2023**
Cours : Analyse mathématique, Algorithmique, Programmation Orientée Objet, SQL.

LANGUES

Anglais TOEIC 830 | **Français** Courant | **Arabe** Langue maternelle